

UNIVERSIDADE DE TRÁS-OS-MONTES E ALTO DOURO

Mestrado em Engenharia e Ciência de Dados

Modelos de Aprendizagem Automática

Aplicação ao dataset Online Retail (UK)

Unidade Curricular: Business Intelligence

Docente: Prof. Tiago Pinto

Aluna:

Francisca Amaro Rodrigues Carvalhais

al2025171727

Maio de 2026

1. Introdução

O presente relatório enquadra-se no âmbito da unidade curricular de Business Intelligence, do Mestrado em Engenharia e Ciência de Dados, e tem como objetivo principal a aplicação de modelos de aprendizagem automática a um dataset real, com vista a desenvolver competências de implementação, avaliação e interpretação crítica de modelos preditivos em contextos de negócio.

O dataset escolhido foi o Online Retail Dataset, disponível publicamente no UCI Machine Learning Repository e no Kaggle. Contém 541.910 transações de uma empresa de retalho online sediada no Reino Unido, registadas entre dezembro de 2010 e dezembro de 2011. O dataset apresenta 8 variáveis originais: Invoice, StockCode, Description, Quantity, InvoiceDate, Price, Customer ID e Country.

Foram implementados três modelos distintos de aprendizagem automática, abrangendo as três principais categorias estudadas: regressão (Random Forest Regressor), classificação (Random Forest Classifier) e agrupamento (K-Means com metodologia RFM). Para cada modelo, foram definidas perguntas de negócio concretas com aplicabilidade prática:

- Modelo 1 — Previsão de vendas mensais por produto, com vista a apoiar a gestão de stock
- Modelo 2 — Identificação de clientes com potencial de recorrência a partir da primeira compra, para apoio a campanhas de fidelização
- Modelo 3 — Segmentação RFM de clientes (Recency, Frequency, Monetary) para estratégias de marketing personalizadas

Todo o trabalho foi desenvolvido em Python, recorrendo às bibliotecas pandas, numpy, matplotlib, seaborn e scikit-learn.

2. Limpeza e Preparação dos Dados

Antes da aplicação dos modelos, foi conduzida uma análise detalhada da qualidade dos dados, com o objetivo de identificar e tratar problemas que pudessem comprometer a fiabilidade dos resultados. Esta fase revelou-se particularmente complexa dada a dimensão e natureza heterogénea do dataset.

2.1 Investigação Inicial

A inspeção inicial revelou diversos problemas que mereceram análise individual:

- 135.080 linhas (24.93%) sem Customer ID — impossibilita análise comportamental do cliente
- 1.454 linhas sem Description — produto desconhecido
- 2.515 linhas com Price = 0 — possíveis ajustes administrativos ou amostras grátis
- 10.624 linhas com Quantity negativa — devoluções de produtos
- 2 linhas com Price negativo — claramente erros ou estornos administrativos
- 5.268 linhas aparentemente duplicadas — necessitam de investigação

2.2 Investigação dos Duplicados

Uma das decisões mais relevantes prendeu-se com o tratamento dos duplicados. Inicialmente equacionou-se mantê-los, partindo do princípio de que poderiam representar compras repetidas legítimas. Para tomar uma decisão fundamentada, foi realizada uma análise comparativa:

- Duplicados considerando todas as colunas (incluindo InvoiceDate ao minuto): 5.268
- Duplicados ignorando a coluna InvoiceDate: 5.269
- Casos onde apenas a hora difere: 1 (com diferença de apenas 1 minuto)

Esta análise demonstrou inequivocamente que os duplicados não correspondem a compras realizadas em momentos distintos, mas sim a erros de registo do sistema (a mesma transação registada duas vezes). Os duplicados foram, por isso, removidos com fundamento.

2.3 Tratamento das Devoluções

As 10.624 linhas com Quantity negativa correspondem a devoluções, identificáveis também pelo prefixo "C" na coluna Invoice. Em vez de simplesmente removê-las (o que perderia informação valiosa), optou-se por mantê-las e criar uma variável categórica TipoTransacao, que classifica cada linha como "Compra" ou "Devolução". Esta abordagem permite análises distintas entre os dois tipos de transação.

2.4 Decisões Finais de Limpeza

Após análise fundamentada de cada caso, foram aplicadas as seguintes operações de limpeza:

Critério	Linhas removidas	Justificação
Customer ID nulo	135.080	Impossibilita análise de cliente
Description nula (restantes)	0	Já removidas no passo anterior
Price $\leq$ 0	40	Ajustes administrativos sem valor
Duplicados	5.225	Erros de registo confirmados
TOTAL REMOVIDO	140.345	25.90% do dataset original

2.5 Novas Variáveis Criadas

- TotalPrice = Quantity $\times$ Price (valor monetário da transação)
- TipoTransacao = "Compra" (392.693 linhas) ou "Devolução" (8.872 linhas)
- InvoiceDate convertida para formato datetime

Após a limpeza, o dataset final ficou com 401.565 linhas e 10 colunas. A taxa global de devolução foi de 2.21%, valor coerente com o esperado para o setor de retalho online.

3. Análise Exploratória dos Dados (EDA)

A análise exploratória teve como objetivo identificar padrões, tendências e relações entre as variáveis do dataset, fundamentando a escolha das perguntas de negócio para os modelos.

3.1 Visão Geral — Produtos e Países

O dataset contém 3.877 produtos únicos vendidos em, aproximadamente, 38 países. A Figura 1 apresenta os produtos e países mais relevantes.




Figura 1 — Top 10 produtos e países por volume e faturação

- O produto mais vendido em quantidade foi PAPER CRAFT LITTLE BIRDIE (aproximadamente 80.000 unidades)
- O Reino Unido domina massivamente o dataset, representando mais de 95% das transações e faturação
- Os principais mercados internacionais são Holanda, Irlanda (EIRE), Alemanha e França

3.2 Análise Temporal

A análise temporal revelou padrões muito claros (Figura 2):




Figura 2 — Padrões temporais: evolução mensal, dia da semana e hora do dia

- Crescimento muito significativo entre agosto e novembro de 2011, com pico em novembro (aproximadamente £1.150.000) — sazonalidade pré-Natal
- Quinta-feira é o dia da semana com maior faturação
- Pico horário às 12h (hora de almoço), com horário típico entre 9h e 16h
- Sábado não regista vendas — a loja provavelmente fecha ao fim de semana parcial

3.3 Análise de Clientes

O dataset apresenta 4.338 clientes únicos. As estatísticas (Figura 3) revelam grande heterogeneidade nos comportamentos de compra:




Figura 3 — Distribuição de gastos, frequência de compras e top clientes

- Gasto médio por cliente: £2.048 | Gasto mediano: £668 (diferença indica distribuição muito assimétrica)

- Número médio de compras por cliente: 4.3
- O cliente que mais gastou atingiu aproximadamente £280.000
- A distribuição em cauda longa sugere a existência de segmentos distintos — fundamento para o Modelo 3 de clustering

3.4 Análise de Devoluções




Figura 5 — Compras vs Devoluções e taxa de devolução por país

- Taxa global de devolução: 2.21% — valor normal para retalho online
- Países com maior taxa de devolução: Austrália (5.9%), Alemanha (4.8%) e Irlanda (3.3%)
- Estes valores podem refletir diferenças culturais ou logísticas (custos de envio internacional)

4. Modelos de Aprendizagem Automática

Foram implementados três modelos, todos baseados em perguntas de negócio reais. Em todos os casos, os dados foram divididos em 80% para treino e 20% para teste, com `random_state = 42` para garantir reprodutibilidade.

4.1 Modelo 1 — Regressão: Previsão de Vendas Mensais

Pergunta de negócio

Será possível prever a quantidade de unidades que cada produto irá vender no próximo mês, com vista a apoiar a gestão de stock, em particular para evitar ruturas no período pré-Natal?

Preparação dos dados

Foi adotado um critério combinado de filtragem dos produtos: incluir produtos vendidos em pelo menos 6 meses diferentes (regulares) OU produtos com pelo menos 50 vendas em 2 ou mais meses (sazonais). Esta abordagem permitiu manter 2.712 dos 3.877 produtos originais, garantindo histórico suficiente para previsão e simultaneamente preservando produtos sazonais com volumes significativos (ex: Hot Water Bottles, comuns em Inverno).

Os dados foram agregados por produto e mês, criando 24.829 combinações produto-mês para treino. Foram criadas 8 features de entrada:

- Mes, Trimestre, EpocaNatal, Verao — captação de sazonalidade

- PrecoMedio — preço médio do produto no mês
- NumTransacoes — número de transações distintas (clientes diferentes que compraram)
- ProdutoEnc — identificação codificada do produto
- VendasMesAnterior_log — vendas no mês anterior (lag feature)

Tratamento de outliers

A distribuição da quantidade vendida revelou-se fortemente assimétrica, enquanto a mediana mensal por produto é de 51 unidades, alguns bestsellers atingem 12.000 unidades. Esta cauda longa prejudicaria o treino do modelo. Para mitigar este efeito sem perder informação, aplicou-se uma transformação logarítmica ao target ($\log(1+y)$), abordagem standard em dados de vendas.

Resultados

Métrica	Valor
R ² (escala log)	0.8553
MAE (escala log)	0.4706
RMSE (escala log)	0.6397
R ² (escala original)	0.7180
MAE (unidades)	69.75
RMSE (unidades)	207.09




Figura 6 — Modelo 1: previsão de vendas com Random Forest (após transformação logarítmica)

Análise de Feature Importance

Feature	Importância
NumTransacoes	66.74%
VendasMesAnterior_log	13.55%
PrecoMedio	12.65%
ProdutoEnc	4.31%
Mes	1.86%
Trimestre, Verao, EpocaNatal	< 1% cada

Interpretação

O modelo explica 86% da variação das vendas mensais na escala logarítmica, com um erro médio absoluto de 70 unidades por produto/mês na escala original — resultado considerado bom para um problema de previsão com elevada heterogeneidade entre produtos.

A análise de feature importance revela uma descoberta interessante: o número de transações (NumTransacoes) é largamente o preditor mais forte (66.7%), seguido pelas vendas no mês anterior (13.5%) e pelo preço médio (12.7%). Surpreendentemente, as variáveis de sazonalidade calendar (mês, trimestre, época do Natal) têm importância muito reduzida.

Esta descoberta merece análise crítica: embora a análise exploratória tenha confirmado o pico de faturação global no período pré-Natal, os resultados do modelo mostram que o mês isolado não é, por si só, um forte preditor das vendas individuais de cada produto. Isto deve-se ao facto de cada produto possuir o seu próprio padrão sazonal, alguns concentram vendas no Inverno, outros no Verão, e muitos vendem de forma regular todo o ano. A sazonalidade existe e é real, mas manifesta-se ao nível do produto individual, sendo capturada de forma indireta pelas variáveis de histórico recente (vendas no mês anterior e número de transações).

4.2 Modelo 2 — Classificação: Cliente Recorrente vs Cliente Único

Pergunta de negócio

Será possível identificar, logo na primeira compra, os clientes que têm maior probabilidade de voltar a comprar? Esta informação permitiria à empresa investir de forma mais eficiente em campanhas de fidelização, focando os recursos nos clientes com maior potencial de recorrência.

Definição das classes

- Cliente Único — apenas 1 fatura (1.493 clientes, 34.4%)
- Cliente Recorrente — 2 ou mais faturas (2.845 clientes, 65.6%)

Features utilizadas

Todas as features foram calculadas apenas a partir da primeira compra de cada cliente, simulando o cenário real onde o modelo precisaria de prever a recorrência sem informação futura:

- ValorPrimeiraCompra — valor total gasto na primeira fatura
- NumProdutos — nº de produtos distintos comprados
- QuantidadeTotal — nº total de unidades adquiridas
- PrecoMedio — preço médio dos produtos escolhidos
- PaisEnc — país do cliente (codificado)
- Mes, DiaSemana — momento da primeira compra

Resultados

Métrica	Valor
Accuracy	71.43%

AUC (ROC)	0.7223
Recall Recorrentes	87%
Recall Únicos	42%
F1-Score Recorrentes	0.80
F1-Score Únicos	0.50




Figura 7 — Modelo 2: matriz de confusão e feature importance

Análise complementar — Curva ROC e ajuste de threshold

Foram realizadas análises complementares para enriquecer a interpretação do modelo (Figura 8):




Figura 8 — Análises complementares: comparação de classes, curva ROC, distribuição de probabilidades e trade-off precision/recall

Sobre o conceito de Threshold

Por defeito, um modelo de classificação binária classifica como "Recorrente" qualquer cliente para quem a probabilidade prevista seja superior a 0.5. No entanto, este ponto de corte (threshold) pode ser ajustado consoante o objetivo de negócio:

Threshold	Accuracy	Recall Recorr.	Comportamento	Aplicação
0.3	69.7%	98.2%	Apanha quase todos os recorrentes	Campanha agressiva
0.4	71.5%	94.7%	Bom equilíbrio	Recomendado
0.5	71.3%	86.8%	Default	Uso geral
0.6	69.4%	74.7%	Mais conservador	Orçamento limitado
0.7	62.9%	57.6%	Apenas casos certos	Recursos escassos

Esta flexibilidade é particularmente valiosa em contextos de negócio: com um threshold baixo (0.3), o modelo identifica 98% dos futuros clientes recorrentes, sendo ideal para campanhas de fidelização em larga escala. Com um threshold mais alto, o modelo torna-se mais seletivo, focando apenas nos clientes com maior probabilidade de retorno, útil quando os recursos de marketing são limitados.

Análise de Feature Importance

Feature	Importância
Mes	20.0%
ValorPrimeiraCompra	19.2%
PrecoMedio	18.9%
QuantidadeTotal	17.5%
NumProdutos	14.7%
DiaSemana	7.3%
PaisEnc	2.4%

Insight de negócio relevante

A comparação entre clientes recorrentes e únicos revelou uma descoberta interessante: os clientes recorrentes preferem produtos com preço médio mais baixo (£3.90) face aos clientes únicos (£5.76). Em termos de valor total da primeira compra e quantidade comprada, os dois grupos são muito semelhantes. Esta observação sugere que os clientes recorrentes podem ter um perfil mais consciente do preço ou efetuar compras com fins comerciais (revenda).

Adicionalmente, o país apresenta importância muito reduzida (2.4%), sugerindo que o comportamento de retenção é semelhante em diferentes mercados, uma boa notícia para estratégias de marketing internacionais.

4.3 Modelo 3 — Clustering RFM: Segmentação de Clientes

Pergunta de negócio

Como agrupar os clientes em segmentos com características distintas (VIP, Fiéis, Em Risco) para que cada grupo receba uma estratégia de marketing personalizada?

Metodologia RFM

A análise RFM (Recency, Frequency, Monetary) é a metodologia padrão da indústria para segmentação de clientes em retalho. Para cada cliente foram calculados três indicadores:

- R (Recency) — dias desde a última compra
- F (Frequency) — número total de compras (faturas distintas)
- M (Monetary) — gasto total acumulado

Pré-processamento

As três variáveis foram transformadas com $\log(1+x)$ para reduzir o efeito dos outliers e depois normalizadas com StandardScaler, passo essencial no K-Means, pois o algoritmo é baseado em distâncias euclidianas e sensível à escala das variáveis.

Validação da escolha de k

Foram aplicados dois métodos para validar a escolha do número de clusters (Figura 9):




Figura 9 — Método do cotovelo e visualização dos 4 clusters identificados

- Método do cotovelo: a inércia estabiliza a partir de $k=4$
- Silhouette Score para $k=4$: 0.338 — clusters razoavelmente separados

Embora $k=2$ obtenha um Silhouette Score superior (0.43), optou-se por $k=4$ porque proporciona uma segmentação mais detalhada e acionável do ponto de vista de negócio. A

separação em apenas 2 grupos seria pouco informativa para campanhas de marketing diferenciadas, esta é uma decisão de trade-off entre rigor matemático e utilidade prática.

Segmentos identificados

Segmento	Cientes	Recency	Frequency	Monetary
VIP	713	12 dias	14	£8.088
Em Risco	1.622	182 dias	1.3	£341
Fiéis (baixos)	837	18 dias	2.2	£557
Fiéis (médios)	1.166	72 dias	4.0	£1.801

Análises complementares




Figura 10 — Análises complementares: Silhouette por k, distribuição por país, faturação e gasto por segmento

Descobertas de negócio

Princípio de Pareto confirmado:

Apenas 16% dos clientes (VIPs) geram 64.9% da faturação total. Os clientes em risco, embora sejam 37% do total, representam apenas 6.2% da faturação. Esta descoberta justifica claramente o investimento prioritário em retenção do segmento VIP.

Diferenças por país:

- Alemanha apresenta a maior percentagem de VIPs (25.5%) — perfil de mercado premium

- Espanha tem mais clientes Fiéis (64.3%) mas poucos VIPs (10.7%) — mercado regular
- Reino Unido, apesar de ser o maior mercado, tem a maior percentagem de clientes Em Risco (37.9%) — sinaliza problema de retenção

Recomendações estratégicas por segmento

Com base nas características reais identificadas pelo modelo, recomendam-se as seguintes ações de negócio para cada segmento:

VIP (16% dos clientes, 65% da faturação):

- Programa de lealdade premium com descontos exclusivos
- Acesso antecipado a novos produtos
- Atendimento personalizado
- Investimento prioritário em retenção

Fiéis (46% dos clientes, 29% da faturação):

- Programa de pontos ou cashback
- Cross-selling baseado no histórico de compras
- Comunicação regular (newsletter)
- Incentivos para aumentar a frequência de compra

Em Risco (37% dos clientes, 6% da faturação):

- Campanha urgente de reativação
- Desconto especial "sentimos a sua falta"
- Inquérito de satisfação para perceber o afastamento
- Email personalizado com produtos relevantes

5. Conclusões e Limitações

O presente trabalho permitiu aplicar com sucesso três modelos distintos de aprendizagem automática a um dataset real de retalho online, abrangendo as três principais categorias estudadas (regressão, classificação e agrupamento) e respondendo a perguntas de negócio com aplicabilidade prática.

5.1 Resumo dos Resultados

Modelo	Métricas	Aplicação
Random Forest (Regressão)	$R^2=0.86$ (log); MAE=70 unidades	Previsão de vendas mensais
Random Forest (Classificação)	Accuracy=71%; AUC=0.72	Identificação de clientes recorrentes
K-Means (RFM)	Silhouette=0.34; 4 segmentos	Segmentação acionável de clientes

5.2 Principais Descobertas

- Os bestsellers concentram-se em produtos de presente e decoração, com forte sazonalidade pré-Natal — o pico de Novembro é 2x superior à mediana mensal
- Apenas 16% dos clientes (segmento VIP) geram 65% da faturação — confirmação do princípio de Pareto
- Clientes recorrentes preferem produtos com preço unitário mais baixo, sugerindo perfil mais consciente do preço
- O mês da primeira compra é o preditor mais forte de recorrência (20% de importância)
- A previsão de vendas baseia-se sobretudo no histórico individual de cada produto — a sazonalidade calendar tem menos peso do que se poderia esperar

5.3 Limitações Identificadas

- O dataset cobre apenas 13 meses, limitando a análise de sazonalidade anual a um único ciclo
- A previsão de vendas seria mais eficaz com técnicas específicas de séries temporais (ARIMA, Prophet), fora do âmbito deste trabalho
- A identificação de clientes únicos vs recorrentes apresenta limitações (recall=42% para únicos), sugerindo que estes clientes têm comportamentos heterogêneos difíceis de capturar
- O Silhouette Score do clustering (0.34) é razoável mas não excelente — os limites entre segmentos contínuos como Recency e Monetary são intrinsecamente difusos

5.4 Reflexão Final

Este trabalho permitiu compreender, na prática, que a aplicação de modelos de aprendizagem automática vai muito além da execução de algoritmos. As principais aprendizagens foram:

Análise crítica dos dados:

A fase de limpeza revelou-se determinante para a qualidade dos resultados. Decisões como investigar os duplicados em detalhe (descobrendo serem erros de sistema), manter as devoluções com classificação separada, ou aplicar transformação logarítmica para mitigar outliers, demonstram que cada decisão deve ser fundamentada nos dados, não em regras automáticas.

Importância da análise crítica dos resultados:

Resultados de métricas elevadas (como $R^2=0.86$) podem ocultar limitações importantes. A análise de feature importance no Modelo 1 revelou que a sazonalidade calendar tem pouco peso, contrariando a hipótese inicial. Esta descoberta, embora aparentemente "negativa", é uma conclusão científica válida e abre caminho para abordagens mais sofisticadas no futuro.

Aplicabilidade real ao negócio:

Os três modelos respondem a perguntas concretas que qualquer empresa de retalho enfrenta: como gerir stock, como identificar clientes fiéis e como segmentar a base de clientes. Os insights extraídos, particularmente o princípio de Pareto e as recomendações por segmento RFM, são imediatamente acionáveis.

Em síntese, mais importante do que obter métricas elevadas é ser capaz de interpretar criticamente os resultados, identificar limitações e propor aplicações práticas, competência que se procurou demonstrar ao longo deste relatório.